PROPUESTA PROYECTO FIN DE CARRERA

Presentado a

LA UNIVERSIDAD DE LOS ANDES
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA ELÉCTRICA Y ELECTRÓNICA

Para obtener el título de

INGENIERO ELECTRÓNICO

por

Sergio David Ferreira Ariza

Implementación de soluciones de aprendizaje por refuerzo a problemas de logística en el ambiente RWARE

Asesor: Fernando Enrique Lozano Martínez, Profesor Asociado, Universidad de Los Andes

Índice

1. Caracterización del problema (Justificación) **3**

2. Marco Teórico **3**
- **2.1. Antecedentes externos** . . . 3
- **2.2. Antecedentes locales** . . . 4

3. Caracterización del proyecto **4**
- **3.1. Objetivo general** . . . 4
- **3.2. Objetivos específicos** . . . 5
- **3.3. Alcance** . . . 5

4. Contexto del proyecto y tratamientos **6**
- **4.1. Suposiciones** . . . 6
- **4.2. Restricciones** . . . 6
- **4.3. Factores de riesgo** . . . 7

5. Cronograma **7**
- **5.1. Diagrama de Gantt** . . . 7
- **5.2. Identificación y descripción de hitos** . . . 8

6. Recursos **8**

1. Caracterización del problema (Justificación)

Con el éxito reciente del aprendizaje de máquina en entornos productivos, cada vez se hace más importante el uso de estos recursos en cadenas de suministro, centros de distribución y sistemas de comercio. En estos escenarios, la operación automatizada con el uso de robots autonómos ndepende únicamente de que estos puedan desplazarse de un punto a otro, sino de que múltiples agentes puedan coordinar sus acciones para cumplir de manera eficiente los objetivos del entorno bajo distintas restricciones. Esta clase de problemas presenta una alta complejidad en dónde el uso de técnicas de *Aprendizaje por Refuerzo Multi-Agente* (MARL)[1] se hace especialmente útil para estudiar las políticas de decisión que logran la capacidad de adaptarse a condiciones variables y optimizar el desempeño global del sistema.

El ambiente RWARE (*Multi-Robot Warehouse*) constituye una plataforma adecuada para abordar este tipo de problemáticas, ya que simula un almacén robotizado en el que varios agentes deben mover estanterías solicitadas hacia zonas de entrega y posteriormente reubicarlas en posiciones disponibles. Este entorno incorpora características relevantes de aplicaciones reales, como observabilidad parcial, acciones discretas, coordinación entre robots, restricciones de movimiento, resolución de colisiones y recompensas escasas asociadas al cumplimiento efectivo de entregas [2, 3]. Estas propiedades hacen que RWARE no sea solamente un escenario de prueba computacional, sino una abstracción útil para analizar los retos de cooperación, asignación de tareas y navegación que aparecen en sistemas logísticos automatizados.

A partir de este ambiente se busca implementar mecanismos de aprendizaje que constituyan políticas óptimas de comportamiento que respondan a las necesidades del entorno. Usando estas implementaciones y métodos en entornos de simulación construyen una base para futuras aplicaciones en entornos reales en donde las ventajas productivas son importantes y tangibles.

2. Marco Teórico

2.1. Antecedentes externos

El aprendizaje por refuerzo, o *Reinforcement Learning* (RL), se ha consolidado como un enfoque fundamental para abordar problemas de toma de decisiones secuenciales en los que un agente aprende a partir de la interacción con un entorno. Sutton y Barto establecen las bases teóricas de este paradigma, definiendo conceptos como política, recompensa, función de valor, exploración, explotación y procesos de decisión de Markov (MDP) [4]. En el contexto de sistemas logísticos, esta formulación resulta relevante porque las decisiones de movimiento, asignación de tareas y priorización de entregas tienen efectos acumulativos sobre el desempeño global del sistema.

El aprendizaje por refuerzo multiagente, o *Multi-Agent Reinforcement Learning* (MARL), extiende estas ideas a entornos donde varios agentes aprenden e interactúan simultáneamente. Albrecht, Christianos y Schäfer presentan MARL como un área que combina aprendizaje por refuerzo, teoría de juegos y aprendizaje profundo para estudiar problemas cooperativos, competitivos y mixtos [1]. En escenarios cooperativos, como los almacenes automatizados, el objetivo consiste en que múltiples agentes aprendan políticas que permitan coordinar sus acciones para maximizar una recompensa común. Esto introduce retos adicionales frente al RL de un solo agente, como la no estacionariedad del entorno, la asignación de crédito entre agentes, la coordinación implícita, la observabilidad parcial y la escalabilidad del entrenamiento.

Por otra parte, Papoudakis et al. resaltan la importancia de realizar evaluaciones sistemáticas

y comparables de algoritmos de MARL en tareas cooperativas [3]. Su trabajo evidencia que el rendimiento de un algoritmo puede variar de forma significativa según la configuración experimental, el entorno utilizado, las métricas seleccionadas y los hiperparámetros de entrenamiento. Por ello, la comparación entre algoritmos debe considerar no solo la recompensa acumulada, sino también indicadores como tasa de éxito, estabilidad del aprendizaje, número de tareas completadas, sensibilidad frente a semillas aleatorias y capacidad de generalización ante escenarios no vistos.

En este marco, RWARE (*Multi-Robot Warehouse*) constituye un entorno de referencia para estudiar problemas de coordinación multiagente en almacenes robotizados. En RWARE, varios agentes deben desplazarse en una grilla, transportar estanterías solicitadas hacia zonas de entrega y evitar conflictos de movimiento en espacios compartidos. Este ambiente permite representar de manera abstracta desafíos reales de logística automatizada, como congestión, asignación de tareas, cooperación entre robots y cumplimiento eficiente de pedidos. Además, su uso en investigaciones de MARL lo convierte en un banco de pruebas adecuado para comparar algoritmos bajo condiciones controladas y reproducibles [2, 3].

2.2. Antecedentes locales

En el contexto local, el uso de aprendizaje por refuerzo multiagente aplicado a entornos como RWARE todavía representa una línea de trabajo emergente. Aunque existen avances académicos en inteligencia artificial, optimización, robótica móvil y simulación de sistemas logísticos, la comparación sistemática de algoritmos de MARL en ambientes de almacén robotizado no se encuentra tan consolidada como en la literatura internacional. Esto abre una oportunidad para desarrollar estudios que adapten metodologías de evaluación modernas a problemas relevantes para la automatización logística y la toma de decisiones distribuida.

A nivel académico, el proyecto se ubica dentro de una tendencia de investigación orientada a estudiar cómo múltiples agentes autónomos pueden coordinarse en entornos simulados antes de considerar implementaciones físicas. Este enfoque es especialmente pertinente en contextos donde el acceso a robots reales, infraestructura de laboratorio o plataformas industriales puede ser limitado. El uso de RWARE permite reducir costos, controlar variables experimentales y analizar de forma reproducible el comportamiento de distintos algoritmos bajo condiciones equivalentes. De esta manera, el entorno simulado funciona como una etapa previa para comprender los retos de coordinación antes de avanzar hacia aplicaciones reales.

Trabajos previos dentro de la universidad, han abordado distintos problemas desde múltiples enfoques, como juegos, agentes de software o elementos inteligentes en microrredes eléctricas [5, 6], sin embargo sobre el ambiente RWARE no se presentan antecedentes de trabajos académicos a nivel institucional. De esta manera, este trabajo puede servir como base para futuras investigaciones locales que busquen integrar MARL con sistemas de planeación, simulación logística o coordinación de flotas de robots móviles.

3. Caracterización del proyecto

3.1. Objetivo general

Comparar el desempeño de diferentes algoritmos de aprendizaje por refuerzo multiagente (MARL) en el ambiente RWARE, mediante la sintonización sistemática de sus parámetros y el análisis de métricas de rendimiento asociadas a coordinación, eficiencia y cumplimiento de tareas, con el fin de

evaluar su pertinencia en problemas de logística automatizada y explorar posibles modificaciones del entorno que permitan integrarlo con un problema de planeación.

3.2. Objetivos específicos

- Caracterizar el ambiente RWARE, identificando sus dinámicas principales, variables de estado, espacio de acciones, estructura de recompensas, restricciones de movimiento y condiciones de interacción entre agentes.
- Seleccionar e implementar algoritmos representativos de MARL que permitan abordar tareas cooperativas en RWARE, considerando enfoques de aprendizaje independiente, entrenamiento centralizado con ejecución descentralizada y métodos actor-crítico multiagente.
- Definir métricas de evaluación para comparar el desempeño de los algoritmos, tales como recompensa acumulada, tasa de entregas completadas, tiempo promedio de finalización, entre otros; de manera que se puedan relacionar con la eficiencia, capacidad de aprendizaje y de cooperación.
- Sintonizar los hiperparámetros de los algoritmos seleccionados, incluyendo tasa de aprendizaje, factor de descuento, tamaño de lote, estrategia de exploración, arquitectura de red y frecuencia de actualización, con el propósito de mejorar la convergencia y el desempeño obtenido durante el entrenamiento.
- Comparar experimentalmente los resultados obtenidos por cada algoritmo bajo escenarios controlados, analizando ventajas, limitaciones y sensibilidad frente a cambios en el número de agentes, tamaño del ambiente, densidad de estanterías y dificultad de las tareas.
- Explorar la viabilidad de modificar el ambiente RWARE mediante la incorporación de dependencias entre paquetes, prioridades de entrega o restricciones de precedencia, de manera que el problema combine coordinación multiagente con elementos propios de planeación y secuenciación de tareas.

3.3. Alcance

El alcance del proyecto comprende el estudio, implementación y comparación experimental de algoritmos de aprendizaje por refuerzo multiagente en el ambiente RWARE, con énfasis en tareas cooperativas de logística automatizada. El trabajo se centrará en evaluar cómo diferentes enfoques de MARL responden ante condiciones controladas del entorno, considerando variaciones en la configuración del almacén, el número de agentes, la complejidad de las tareas y los parámetros de entrenamiento. A partir de estos experimentos se busca identificar qué algoritmos presentan mejor desempeño en términos de eficiencia operacional, estabilidad de aprendizaje, coordinación entre agentes y capacidad para completar entregas dentro del ambiente simulado.

El proyecto incluirá una etapa de caracterización del entorno RWARE, en la cual se analizarán sus reglas de operación, observaciones disponibles, acciones permitidas, recompensas y restricciones asociadas al movimiento de los agentes. Posteriormente, se seleccionarán algoritmos representativos de MARL y se realizará su entrenamiento bajo escenarios comparables. La evaluación se apoyará en métricas cuantitativas como recompensa acumulada, número de entregas completadas, tiempo promedio de ejecución, tasa de éxito, comportamiento durante el entrenamiento y sensibilidad frente

a cambios en los hiperparámetros. Esta comparación permitirá establecer criterios para determinar las ventajas y limitaciones de cada enfoque en problemas de coordinación multiagente.

Asimismo, el alcance contempla la sintonización de hiperparámetros relevantes para mejorar el rendimiento de los modelos entrenados. Esta sintonización se realizará de manera experimental, modificando parámetros como tasa de aprendizaje, factor de descuento, estrategia de exploración, tamaño de lote, arquitectura de red y frecuencia de actualización. El propósito no será obtener una solución óptima universal, sino analizar cómo estas decisiones afectan el aprendizaje y el desempeño de los agentes en el contexto específico de RWARE.

Como componente exploratorio, se estudiará la viabilidad de modificar el ambiente para incorporar elementos propios de un problema de planeación. En particular, se considerará la inclusión de dependencias entre paquetes, restricciones de precedencia, prioridades de entrega o secuencias obligatorias de tareas. Esta extensión permitirá analizar si el entorno puede representar problemas más cercanos a escenarios reales, donde no todos los pedidos son independientes y donde la toma de decisiones debe considerar tanto la coordinación física de los robots como la planificación lógica de las entregas.

El proyecto se desarrollará en un entorno simulado, por lo que no contempla la implementación en robots físicos ni la validación en un almacén real. Tampoco se pretende construir una plataforma logística completa, sino utilizar RWARE como banco de pruebas para comparar algoritmos, ajustar parámetros y explorar modificaciones del ambiente. Los resultados esperados corresponden a un análisis experimental y académico que sirva como base para futuras investigaciones en MARL aplicado a logística, planeación automática y sistemas multiagente cooperativos.

4. Contexto del proyecto y tratamientos

4.1. Suposiciones

- Se supone versionamiento estable y compatible de las librerías usadas para la simulación del entorno y las implementaciones de los algoritmos de aprendizaje.
- Se supone que el ambiente RWARE permite configurar escenarios con diferentes tamaños de almacén, número de agentes y niveles de dificultad, de manera que sea posible realizar comparaciones experimentales controladas.
- Se supone que los algoritmos seleccionados de MARL pueden entrenarse y evaluarse en el entorno simulado con los recursos computacionales disponibles para el proyecto.
- Se supone que las condiciones iniciales, semillas de aleatoriedad y configuraciones de entrenamiento pueden registrarse para favorecer la reproducibilidad de los experimentos.
- Se supone que las modificaciones exploratorias al ambiente, como dependencias entre paquetes, prioridades o restricciones de precedencia, pueden implementarse sin alterar la lógica base de RWARE de forma que impida comparar los resultados con el entorno original.

4.2. Restricciones

- El desarrollo del proyecto depende de la disponibilidad de recursos computacionales suficientes para la ejecución de los experimentos, especialmente para sintonizar los hiperparámetros del ambiente.

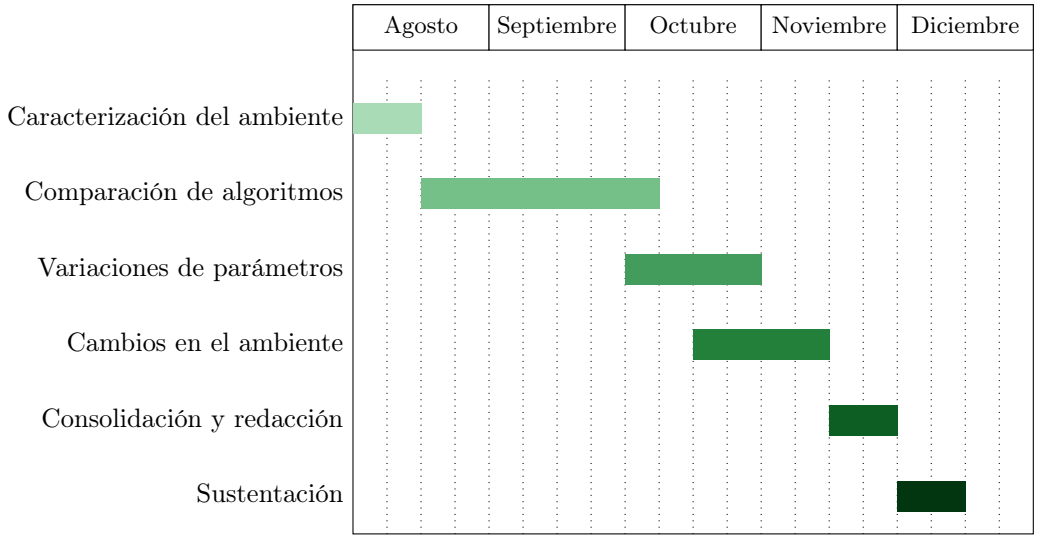
- El uso y acceso al código fuente de librerías y utilidades está sujeto a la disponibilidad provista por los poseedores de los mismos.

4.3. Factores de riesgo

- Los algoritmos de MARL pueden presentar alta variabilidad en los resultados debido a la aleatoriedad del entrenamiento, la inicialización de las redes y la interacción simultánea entre múltiples agentes.
- El entrenamiento puede requerir tiempos de ejecución elevados, especialmente durante la sintonización de hiperparámetros o al evaluar escenarios con mayor número de agentes y configuraciones más complejas del almacén.
- La modificación del ambiente RWARE para incluir dependencias entre paquetes, prioridades o restricciones de precedencia puede aumentar la complejidad del problema y generar errores en la lógica de simulación si no se valida cuidadosamente.
- La compatibilidad entre versiones de librerías, paquetes de simulación y código de entrenamiento puede afectar la reproducibilidad de los experimentos o requerir ajustes adicionales durante la implementación.
- La capacidad computacional disponible puede limitar el número de experimentos, repeticiones, semillas o configuraciones evaluadas, reduciendo el alcance del análisis estadístico de los resultados.

5. Cronograma

5.1. Diagrama de Gantt



5.2. Identificación y descripción de hitos

A continuación se describen los hitos clave del proyecto de acuerdo con las fases definidas en el diagrama de Gantt.

Nº	Fase	Hito	Fecha estimada
1	Caracterización del ambiente	Revisión del funcionamiento de RWARE, observaciones, acciones, recompensas y configuraciones del entorno.	Agosto de 2026
2	Caracterización del ambiente	Definición de escenarios experimentales iniciales, métricas de evaluación y criterios de comparación para los algoritmos	Agosto de 2026
3	Comparación de algoritmos	Selección e implementación de los algoritmos MARL que serán evaluados en el ambiente RWARE.	Septiembre de 2026
4	Comparación de algoritmos	Comparación experimental del desempeño de los algoritmos según métricas establecidas.	Septiembre de 2026
5	Comparación de algoritmos	Sintonización de hiperparámetros y comparación de algoritmos en escenario estándar.	Septiembre de 2026
6	Variaciones de parámetros	Análisis de sensibilidad frente a cambios en el número de agentes, tamaño del almacén, y otros escenarios.	Octubre de 2026
7	Cambios en el ambiente	Diseño e implementación exploratoria de modificaciones en RWARE, incorporando dependencias entre paquetes, prioridades o restricciones.	Noviembre de 2026
9	Cambios en el ambiente	Evaluación comparativa entre el ambiente original y el ambiente modificado.	Noviembre de 2026
10	Consolidación y redacción	Organización de resultados, análisis final y redacción del documento del proyecto.	Noviembre de 2026

6. Recursos

A continuación se describen los recursos principales requeridos y su función dentro del proyecto:

- **Equipo de cómputo:** Se utilizará una máquina (física o virtual) con capacidad suficiente para ejecutar entrenamientos de algoritmos de aprendizaje por refuerzo multiagente, almacenar resultados experimentales y realizar análisis comparativos.
- **Python:** Será el lenguaje principal para la implementación, ejecución y análisis de los experimentos.
- **Ambiente RWARE:** Se empleará como entorno de simulación para representar un almacén robotizado multiagente.

- **Librerías de aprendizaje por refuerzo y aprendizaje profundo:** Se utilizarán paquetes de software compatibles con la implementación de algoritmos de MARL, redes neuronales, entrenamiento de políticas y evaluación experimental.
- **Herramientas de análisis de datos:** Se emplearán librerías como NumPy, pandas y herramientas de visualización para organizar métricas, procesar resultados, comparar desempeños y generar gráficas.
- **Sistema de control de versiones:** Se utilizará un repositorio de código en git para registrar cambios en la implementación, conservar configuraciones experimentales, documentar modificaciones al ambiente y facilitar la reproducibilidad del proyecto.
- **Herramientas de documentación:** Se utilizará LaTeX para la escritura del documento final, organización de referencias, presentación de tablas, figuras, cronograma y resultados obtenidos durante el desarrollo del proyecto.

Anexos

- Presentación de propuesta de grado firmada por el asesor académico, profesor Fernando Enrique Lozano.
- Autorización de uso del trabajo a favor de la Universidad de los Andes.

Referencias

[1] S. V. Albrecht, F. Christianos, and L. Schäfer, *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. Cambridge, MA: MIT Press, 2024. [Online]. Available: https://www.marl-book.com/

[2] F. Christianos, L. Schäfer, and S. Albrecht, "Shared experience actor-critic for multi-agent reinforcement learning," in *Advances in Neural Information Processing Systems*, vol. 33. Curran Associates, Inc., 2020, pp. 10 707–10 717. [Online]. Available: https://proceedings.neurips.cc/paper/2020/file/7967cc8e3ab559e68cc944c44b1cf3e8-Paper.pdf

[3] G. Papoudakis, F. Christianos, L. Schäfer, and S. V. Albrecht, "Benchmarking multi-agent deep reinforcement learning algorithms in cooperative tasks," in *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021. [Online]. Available: https://openreview.net/forum?id=cIrPX-Sn5n

[4] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA: MIT Press, 2018. [Online]. Available: http://incompleteideas.net/book/the-book-2nd.html

[5] C. Garrido, "Energy management system for microgrids based on deep reinforcement learning," 2021. [Online]. Available: https://hdl.handle.net/1992/58828

[6] L. Medina, "Constructing a language for testing reinforcement learning programs using nlp techniques," 2025. [Online]. Available: https://hdl.handle.net/1992/76816